Estadística descriptiva

Martin Trombetta

Universidad de Buenos Aires

Maestría en Economía Aplicada

2024

Introducción

Se llama estadística descriptiva a un conjunto de técnicas utilizadas para caracterizar un conjunto de datos provenientes de una muestra o lo que llamaremos una **distribución empírica**

Comenzaremos por presentar diversos recursos de **análisis gráfico** de distribuciones empíricas

Luego, discutiremos 4 tipos de medidas relevantes:

1. Medidas de tendencia central
2. Medidas de variabilidad
3. Medidas de posición
4. Medidas superiores

Bibliografía sugerida: NC1-2

Población y muestra

Llamamos **población** al conjunto de todos los elementos que forman parte de un universo de interés. El tamaño de la población siempre es suficientemente grande como para que no podamos observarla (podría ser infinito)

Llamamos **muestra** a un subconjunto de la población que es observado para el análisis estadístico

Algunos ejemplos clásicos de muestras: encuestas, recortes temporales, extracción de sangre, los alumnos de este curso

Tipos de variables

Las variables de interés en el análisis estadístico pueden dividirse en dos grupos:

- Variables cuantitativas: aquellas que expresan cantidades numéricas
  - Variables discretas: aquellas que asumen valores en **conjuntos numerables** (calificación en un examen, cantidad de hijos)
  - Variables continuas: aquellas que asumen valores en **conjuntos no numerables** (temperatura, distancia)
- Variables cualitativas: aquellas que expresan la presencia o ausencia de un atributo que no es cuantificado (género, procedencia)

Frecuencias

Sea n el tamaño de la muestra

La **frecuencia absoluta** f_i de una observación i es la cantidad de veces que esta aparece en la muestra

La **frecuencia relativa** fr_i de una observación i es la proporción de veces que esta aparece en la muestra:

$$fr_i = \frac{f_i}{n} \tag{1}$$

Frecuencias acumuladas

La **frecuencia acumulada** a_i de una observación i es la cantidad de observaciones iguales o menores a esta en la muestra

La **frecuencia relativa acumulada** ar_i de una observación i es la proporción de observaciones iguales o menores a esta en la muestra:

$$ar_i = \frac{a_i}{n} \tag{2}$$

Cantidad de niños por hogar EPH 3T23

Niños en el hogar	Frecuencia absoluta	Frecuencia relativa	Frecuencia acumulada	Frecuencua relativa acumulada
0	9864	0.5922	9864	0.5922
1	3218	0.1932	13082	0.7854
2	2308	0.1386	15390	0.924
3	905	0.0543	16295	0.9783
4	221	0.0133	16516	0.9916
5	140	0.0084	16656	1
Total	16656	1		

Histograma de frecuencias absolutas

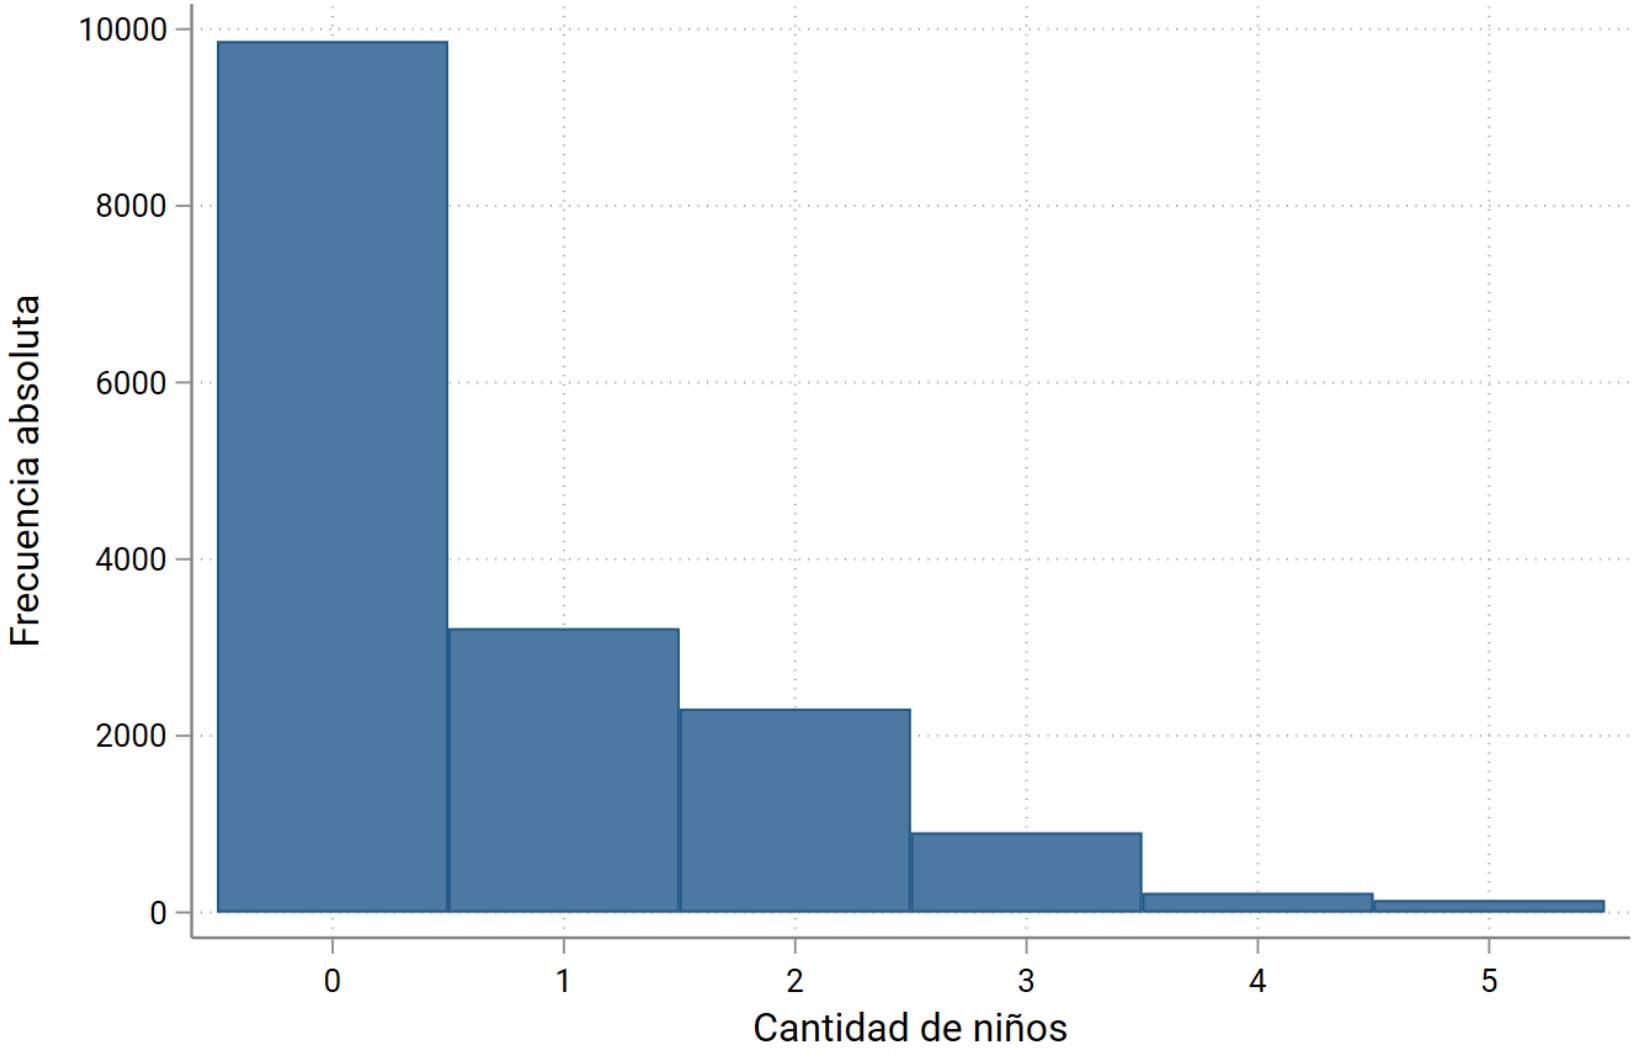

Histograma de frecuencias relativas

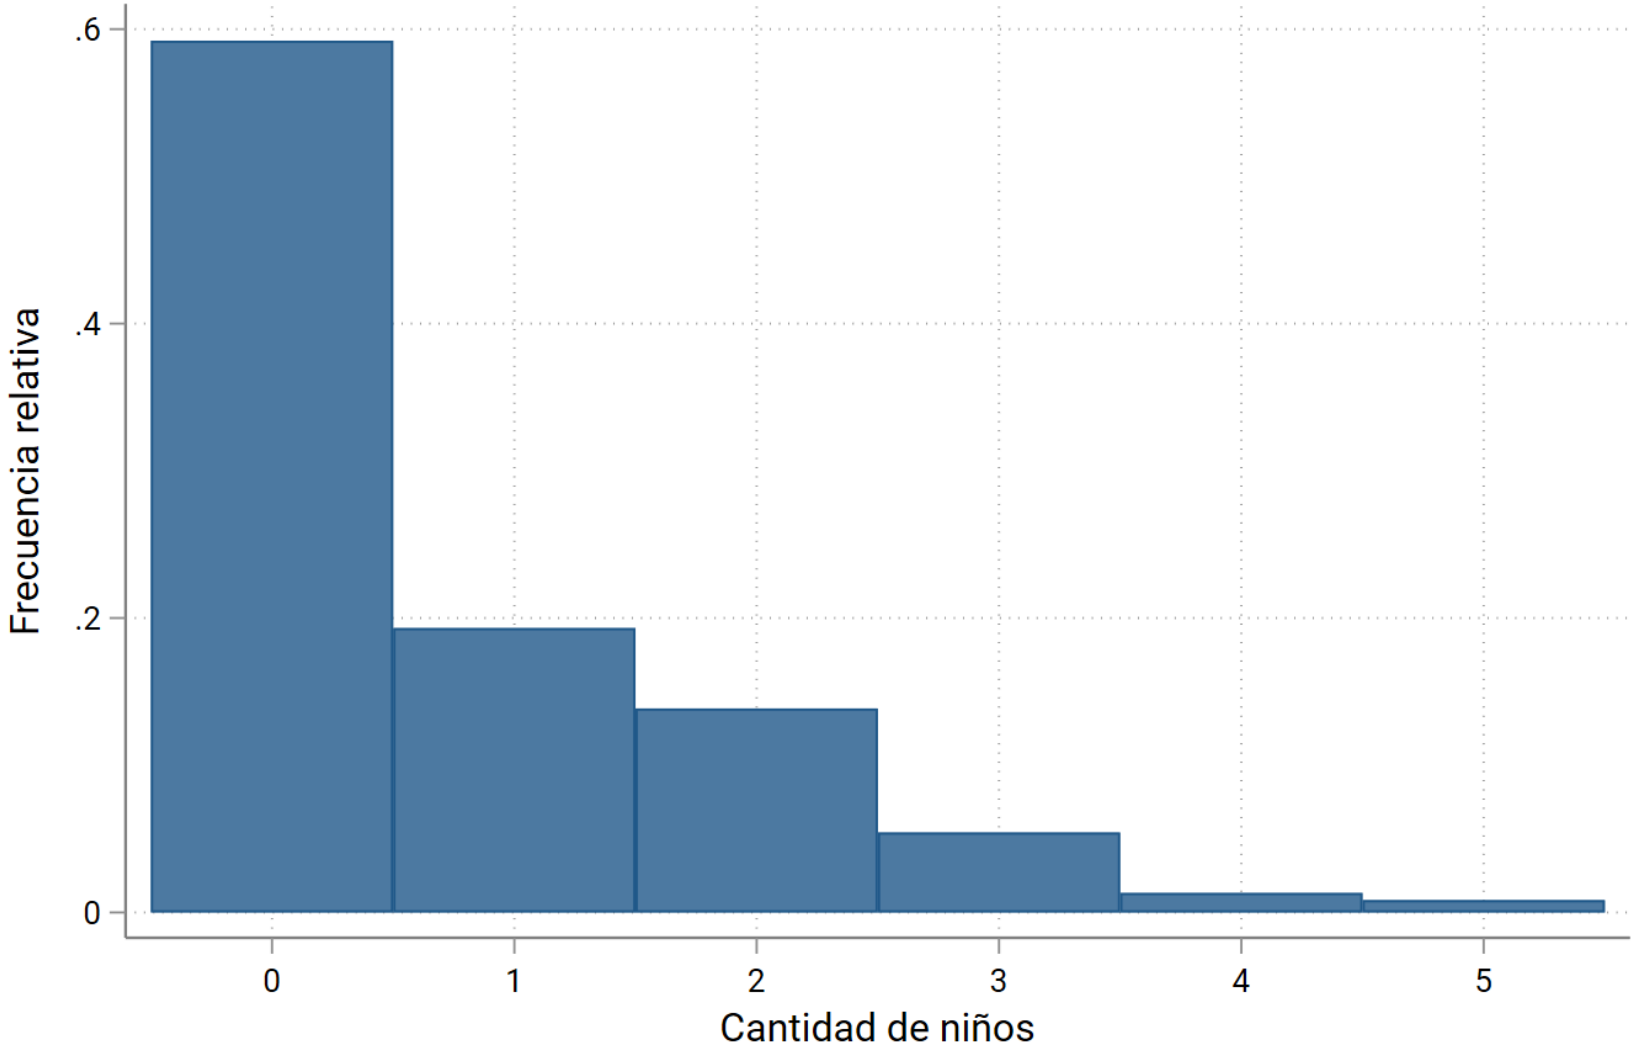

Histograma de frecuencias acumuladas

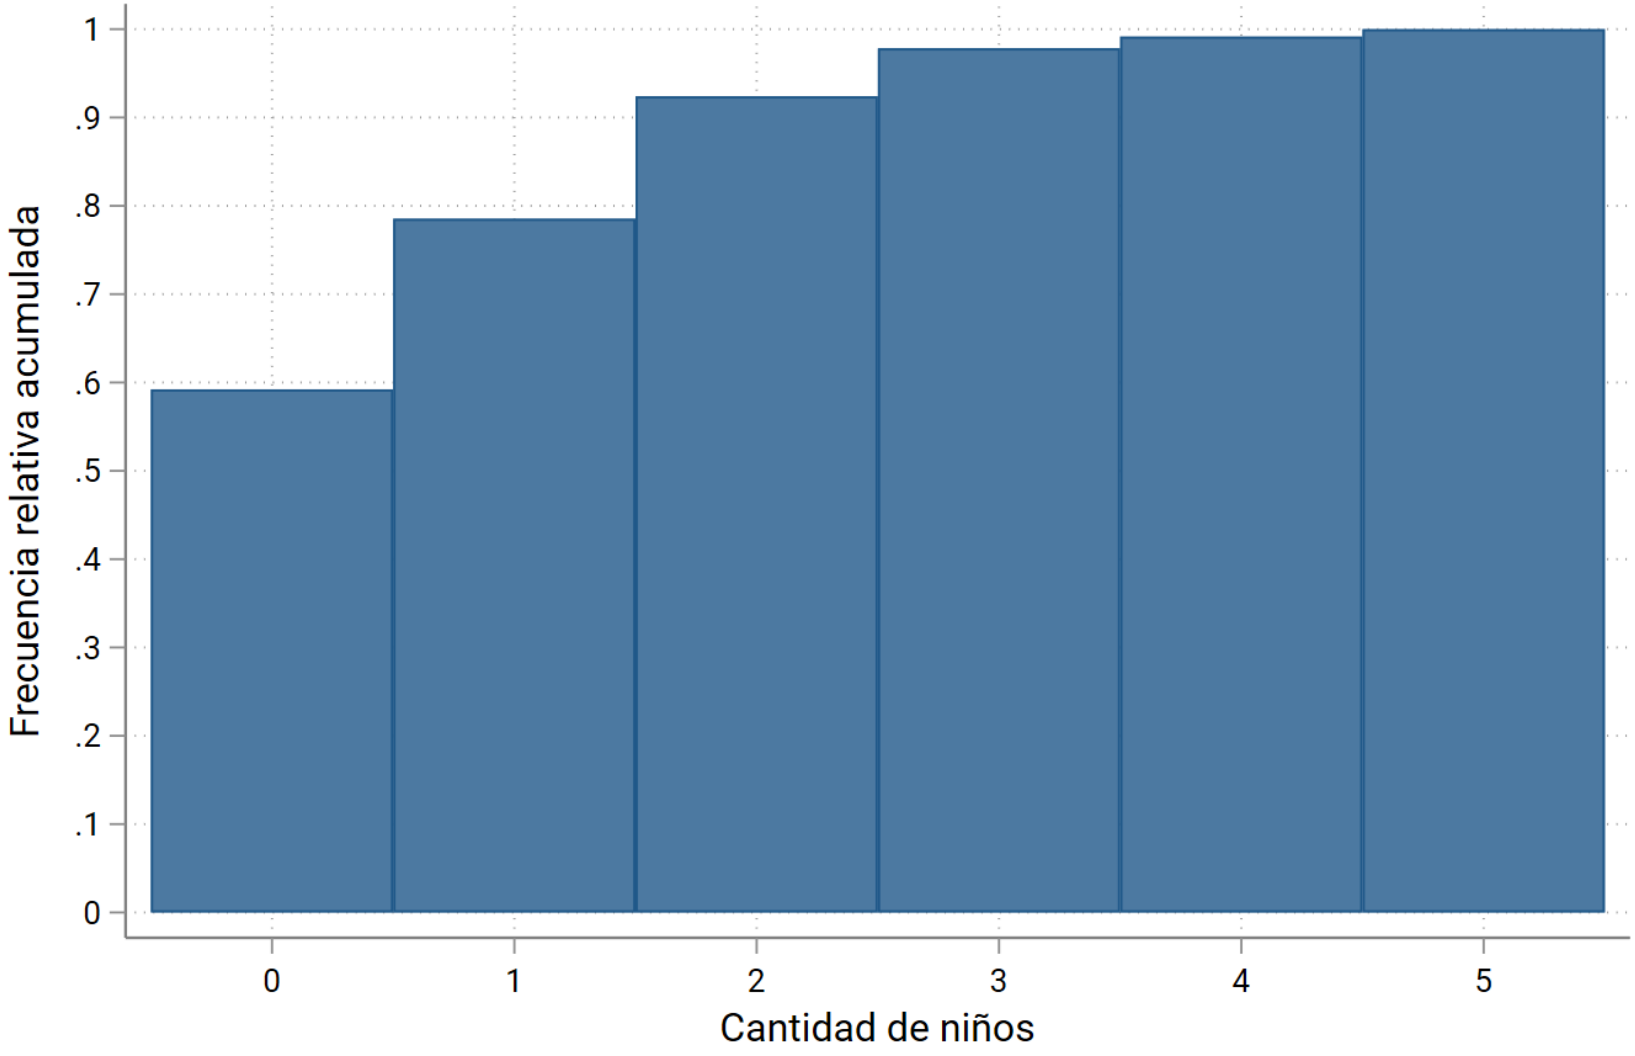

Medidas de tendencia central

Las medidas de tendencia central sirven para caracterizar la localización de los datos. Vamos a presentar 3 medidas de tendencia central distintas:

- Media
- Mediana
- Moda

Media

La **media aritmética** (también conocida como "media" o "promedio") es la medida descriptiva por excelencia. Su uso habitual la vuelve muy fácil de calcular e interpretar.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i \tag{3}$$

Problemas:

- Muy sensible a *outliers* (valores atípicos)
- Poco representativa en distribuciones muy asimétricas

Distribución del salario EPH 3T23

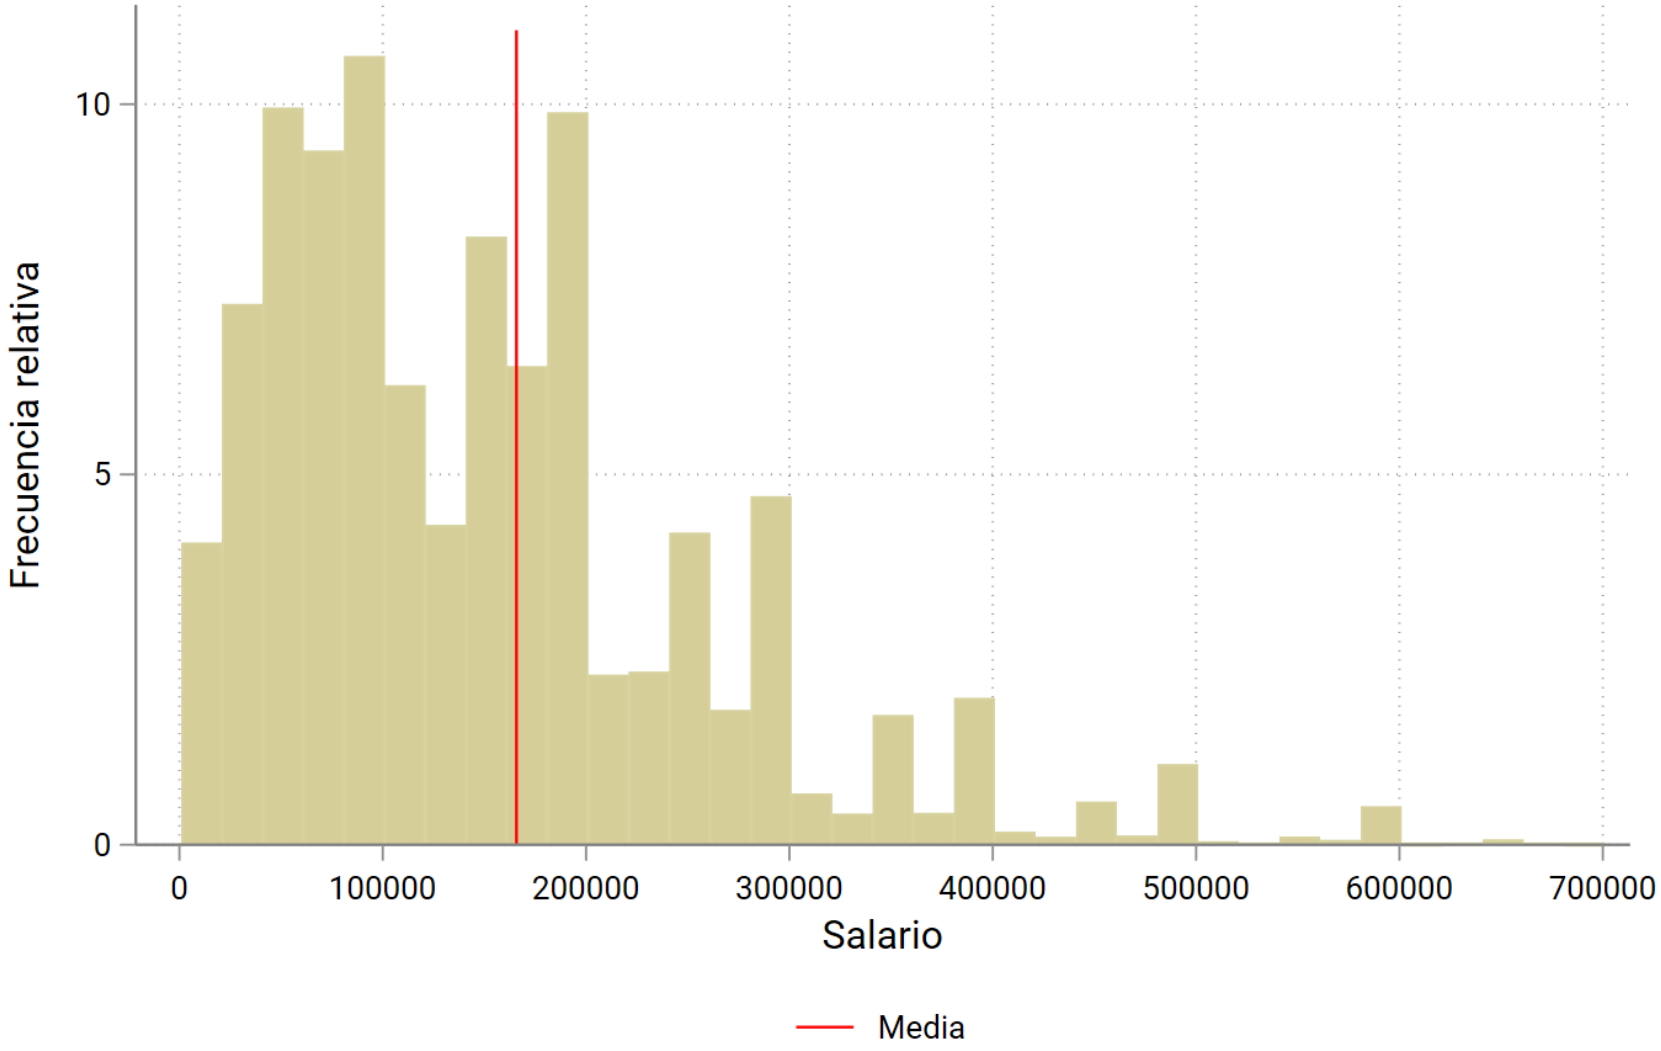

Mediana

Ordenamos los datos de menor a mayor:

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \ldots \leq x_{(n)}$$

La **mediana** es el valor que ocupa la posición intermedia en la distribución empírica. En otras palabras, la mediana separa el 50 % de los valores más pequeños de la distribución del 50 % de los valores más grandes de la distribución

La mediana no es sensible a la presencia de *outliers* ni a la asimetría de la distribución

Mediana

La posición intermedia solo está definida si n es impar. Cuando n es par, se promedian los dos elementos intermedios:

$$Me = \begin{cases} x_{\left(\frac{n}{2}+\frac{1}{2}\right)} & \text{si } n \text{ es impar} \\ \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2} & \text{si } n \text{ es par} \end{cases} \tag{4}$$

Distribución del salario EPH 3T23

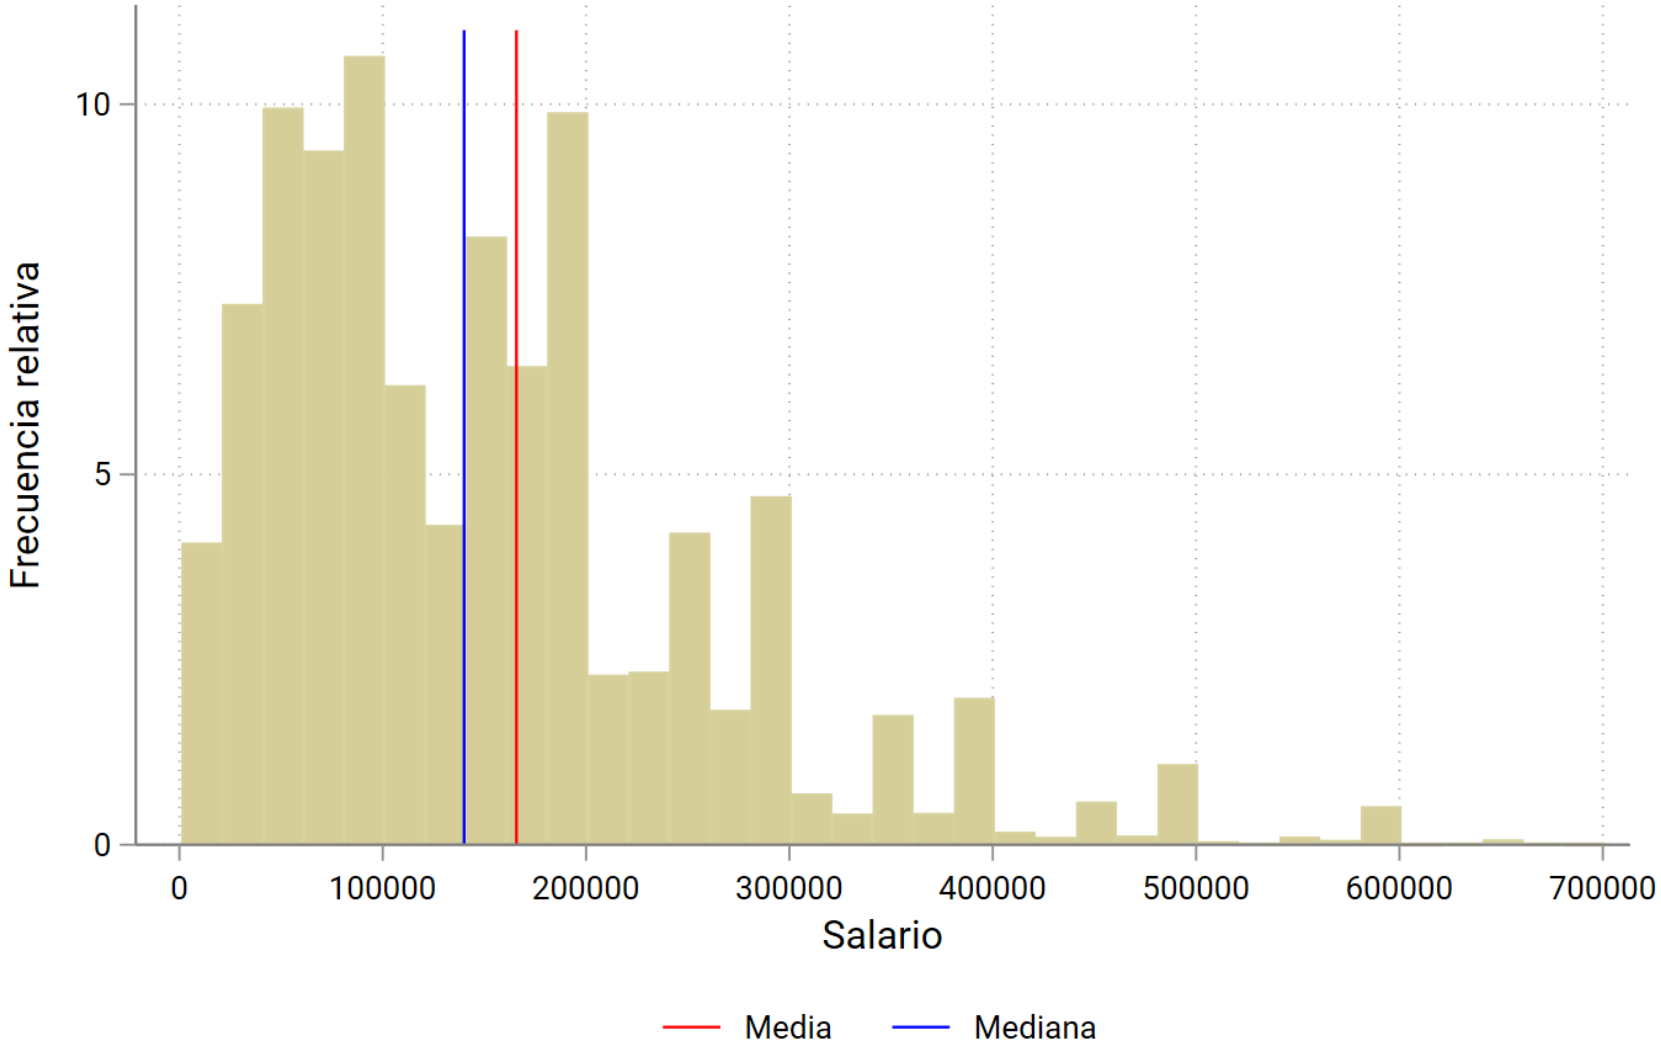

Moda

La **moda** (o modo) es la observación con mayor frecuencia en la distribución empírica. No necesariamente es única. Cuando una distribución tiene más de un modo, decimos que es multimodal

Ejemplos clásicos de **distribuciones bimodales**: distribuciones con "élite", polarización política

Medidas de variabilidad

Las medidas de variabilidad sirven para caracterizar el nivel de dispersión de los datos. Cuanto mayor sea la dispersión de los datos en una distribución empírica, menos informativas son las medidas de tendencia central y viceversa. Vamos a presentar 3 medidas de variabilidad distintas:

- Varianza
- Desvío estándar
- Coeficiente de variabilidad

Varianza

La **varianza** es la media de las desviaciones cuadráticas respecto de la media

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 \tag{5}$$

Se eleva las desviaciones al cuadrado ya que de otro modo la compensación de signos haría que el resultado no fuera útil

Por qué se divide por $n-1$ y no por n? Lo discutiremos más adelante

Desvío estándar

La varianza está expresada en unidades cuadráticas, lo cual dificulta su interpretación. Por ese motivo definimos el **desvío estándar** como la raíz cuadrada de la varianza

$$s = \sqrt{s^2} \tag{6}$$

Coeficiente de variación

Por último, puede ser útil expresar el desvío estándar en unidades relativas en lugar de absolutas. Así definimos el **coeficiente de variación**

$$CV = \frac{s}{\bar{x}} \tag{7}$$

El coeficiente de variación mide el tamaño del desvío en relación al de la media. No necesariamente debe ser menor que 1

Un coeficiente de variación alto (digamos, mayor a 0.5) indica que la media puede no ser una buena medida

En la distribución del salario de la EPH 3T23, el desvío estándar es de 155458, lo cual arroja un CV de 1.1

Medidas de posición

Las medidas de posición sirven para caracterizar la forma de una distribución empírica calculando puntos de localización que no necesariamente son los centrales

Una medida de posición elemental es el **rango**

$$R = x_{(n)} - x_{(1)} \tag{8}$$

En la distribución del salario de la EPH 3T23, el rango es 7999000 (ya que los valores de los extremos son 1000 y 8000000)

Sin embargo, las medidas de posición más relevantes son los **cuantiles**

Cuantiles

Los cuantiles son los valores que dividen la distribución empírica en una cantidad arbitraria de partes iguales. Algunos ejemplos de cuantiles utilizados frecuentemente son:

- Cuartiles
- Quintiles
- Deciles
- Percentiles

La mediana es un cuantil (medida de tendencia central y de posición al mismo tiempo)

Percentiles

Veamos cómo se calcula un percentil genérico

$$\underbrace{x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \cdots}_{\alpha\,\%} \leq P_\alpha \leq \underbrace{\cdots \leq x_{(n-1)} \leq x_{(n)}}_{(100-\alpha\,\%)}$$

P_α es tal que el $\alpha\,\%$ de los valores de la distribución son menores a P_α y el $(100-\alpha)\,\%$ de los valores son mayores a P_α

Percentiles

Definimos

$$i = \frac{\alpha}{100} \cdot n$$

Si i no es entero, sea i' el correspondiente redondeo hacia arriba. Entonces la fórmula de cálculo es:

$$P_\alpha = \begin{cases} \dfrac{x_{(i)} + x_{(i+1)}}{2} & \text{si } i \text{ es entero} \\ x_{(i')} & \text{si } i \text{ no es entero} \end{cases} \tag{9}$$

Percentiles

El resto de los cuantiles puede calcularse como casos particulares de percentiles. Veamos algunos ejemplos:

$$
\begin{aligned}
C_1 &= P_{25} \\
C_3 &= P_{75} \\
C_2 &= Me = P_{50} \\
Q_1 &= P_{20} \\
Q_4 &= P_{80}
\end{aligned}
$$

Algunos percentiles de la distribución del salario en la EPH 3T23: $P_1 = 10000$, $P_{25} = 75000$, $P_{75} = 200000$, $P_{99} = 700000$

Medidas superiores

Las medidas superiores caracterizan aspectos más complejos de una distribución empírica. Vamos a presentar 2 medidas superiores distintas:

- Coeficiente de asimetría
- Coeficiente de curtosis

Coeficiente de asimetría

El **coeficiente de asimetría** mide el grado de asimetría en la distribución o cuánto esta se aleja de la simetría perfecta

$$A = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^3}{ns^3} \tag{10}$$

Si $A > 0$, la distribución es **asimétrica positiva** (o asimétrica a derecha), lo que indica mayor concentración de valores inferiores a la media

Si $A < 0$, la distribución es **asimétrica negativa** (o asimétrica a izquierda), lo que indica mayor concentración de valores superiores a la media

Si $A = 0$, la distribución es **simétrica**

Coeficiente de asimetría: ejemplos

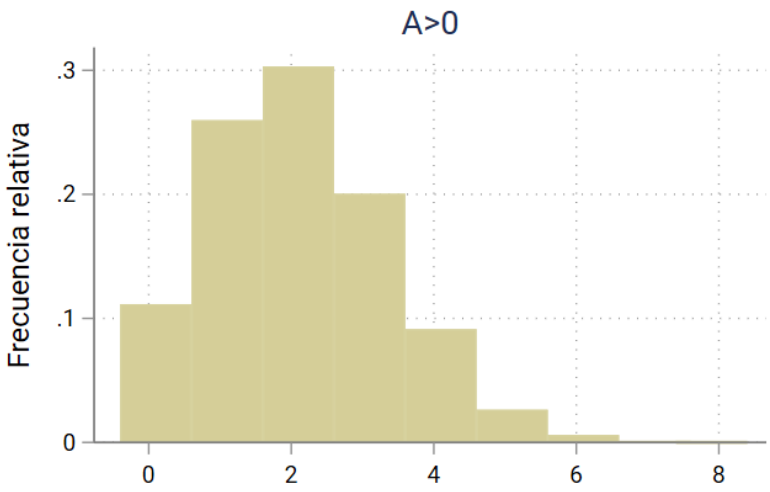

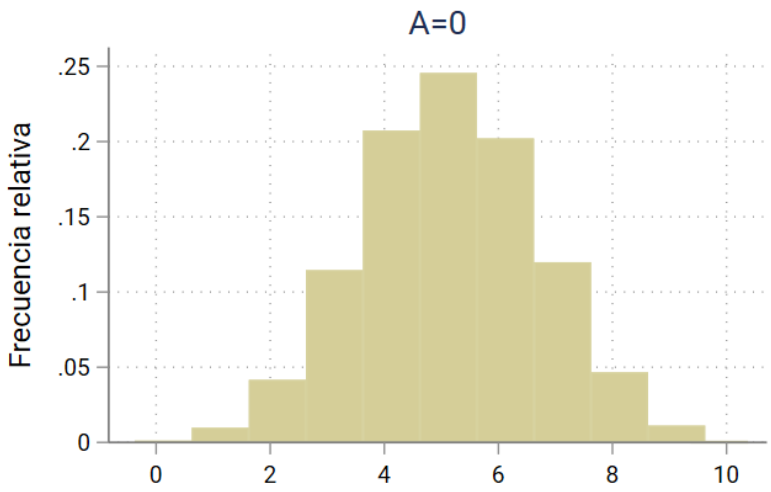

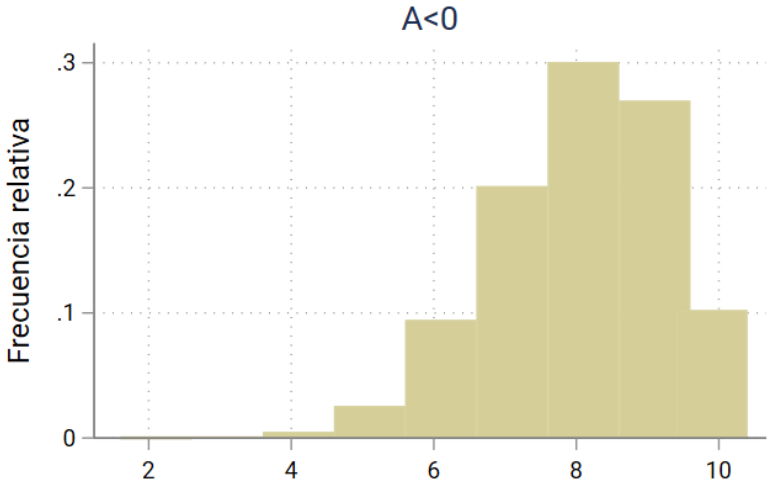

Coeficiente de curtosis

El **coeficiente de curtosis** mide qué tan pesadas son las colas de la distribución

$$K = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^4}{ns^4} \tag{11}$$

Si $K > 3$, la distribución es **leptocúrtica** (colas pesadas), lo que indica alta concentración de valores "extremos"

Si $K < 3$, la distribución es **platicúrtica** (colas livianas), lo que indica baja concentración de valores "extremos"

Si $K = 3$, la distribución es **mesocúrtica**
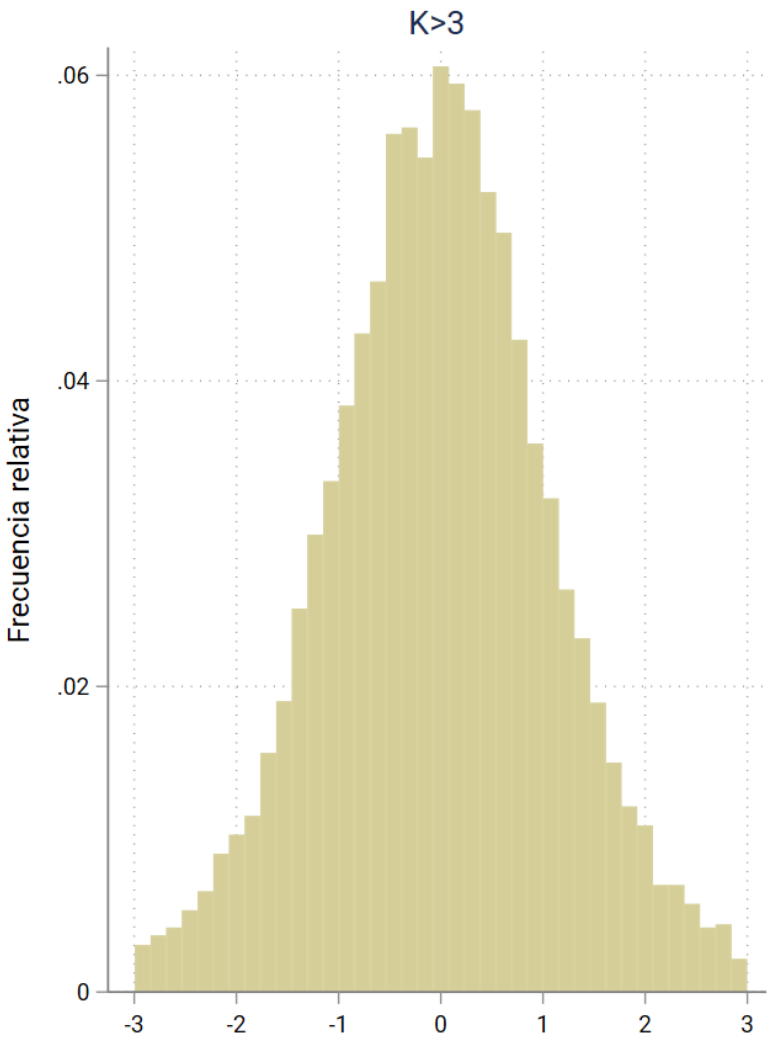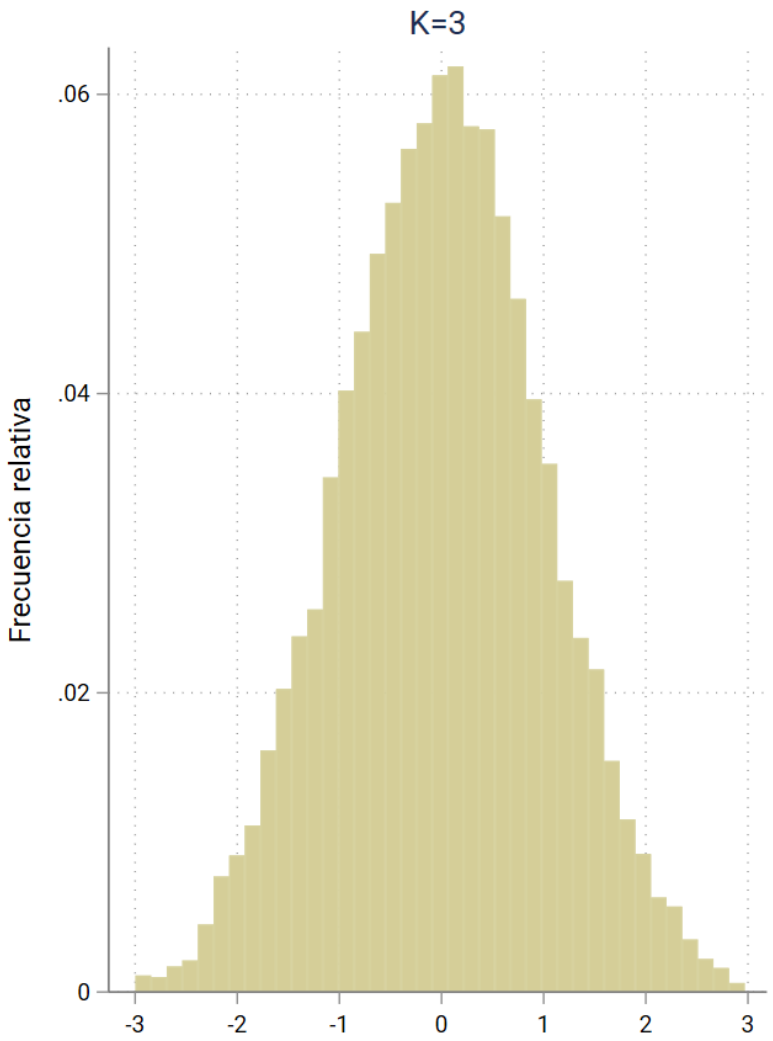
Coeficiente de curtosis: ejemplos