

.UBAeconómicas **posgrado**

ENAP Escuela de Negocios y Administración Pública

Universidad de Buenos Aires
Facultad de Ciencias Económicas
Escuela de Negocios y Administración Pública

MAESTRÍA EN ECONOMÍA APLICADA

PROYECTO
TRABAJO FINAL DE MAESTRÍA

Aprendizaje Automático Doble para Diferencias en
Diferencias: Fundamentos y Aplicación

AUTOR: MARTÍN GABRIEL CARGNEL

DIRECTOR: MARÍA NOELIA ROMERO

[MARZO 2026]

1. Resumen del Proyecto

Este proyecto de tesis investiga la intersección entre el aprendizaje automático (*Machine Learning*) y la inferencia causal, enfocándose específicamente en la implementación del marco de *Double Machine Learning* (DML) dentro de los diseños de Diferencias en Diferencias (DiD). Históricamente, las metodologías de ML han sido relegadas a tareas puramente predictivas, mientras que la econometría se ha centrado en la identificación y estimación de coeficientes causales. Sin embargo, el DML surge como una solución robusta que permite integrar la capacidad de procesamiento de datos de alta dimensionalidad característica del ML, garantizando simultáneamente la validez estadística y la insesgadez necesaria para la estimación de efectos de tratamientos mediante la ortogonalización. Dado que esta metodología es relativamente nueva, con sus bases establecidas formalmente a partir de 2018, resulta de interés profundizar en su estudio para delimitar sus alcances y versatilidad en la econometría aplicada.

En la primera parte del estudio, se revisan los fundamentos teóricos del DML en contraposición a los estimadores econométricos tradicionales, haciendo foco en las limitaciones de estos últimos, que dan lugar al uso de nuevas metodologías como DML. Este análisis provee el marco conceptual necesario para que el lector comprenda la interpretación técnica de los resultados posteriores. En la etapa empírica, se contrastan los estimadores de econometría tradicional con los de ML en dos escenarios fundamentales: un diseño canónico de tratamiento simultáneo y un esquema de adopción escalonada (*staggered adoption*). El objetivo central es determinar en qué condiciones los resultados del DML difieren de los estimadores clásicos. La investigación demuestra que, en entornos simples, ambas metodologías presentan resultados similares; no obstante, ante la presencia de adopción escalonada y muchas covariables, los resultados de los estimadores clásicos resultan sesgados y anti-intuitivos, mientras que DML presenta resultados alineados a los de la bibliografía.

2. Justificación

Existe una dicotomía histórica en estadística aplicada entre predecir y explicar, tal como lo destacó Breiman (2001) en su influyente trabajo sobre las "dos culturas" del modelado estadístico. Por un lado, la cultura del modelado de datos, predominante en la econometría tradicional, asume que los datos son generados por un modelo conocido (por ejemplo, regresión lineal) y se enfoca en la inferencia de parámetros. Por otro lado, la cultura del modelado algorítmico, base del Aprendizaje Automático (ML), trata el mecanismo

generador de datos como desconocido y complejo, enfocándose casi exclusivamente en la precisión predictiva.

Los métodos de ML, como *random forest* o las redes neuronales, han demostrado ser excelentes para predecir, capturando relaciones no lineales complejas e interacciones de alto orden que los modelos tradicionales pasan por alto. Sin embargo, a menudo son "cajas negras" difíciles de interpretar causalmente, lo que ha generado escepticismo entre economistas y científicos sociales cuyo objetivo es entender por qué ocurre un fenómeno (explicar) y cómo una intervención afecta un resultado (inferencia causal).

Por otro lado, los métodos econométricos tradicionales son interpretables, pero pueden sufrir de sesgos severos por "mala especificación del modelo" al tener que asumir una forma funcional rígida (linealidad, aditividad, etc.). Si la verdadera relación entre las variables es más compleja, un modelo lineal simple no logrará controlar adecuadamente, resultando en estimaciones sesgadas.

La justificación de este trabajo radica en el estudio de herramientas que combinen lo mejor de ambos mundos: la flexibilidad y poder predictivo del ML para modelar las variables de control ("*nuisance*") y el rigor de la teoría de inferencia causal para obtener estimadores insesgados y realizar pruebas de hipótesis válidas. El marco de *Double Machine Learning* (DML), propuesto por Chernozhukov et al. (2018), ofrece una solución teóricamente robusta a este problema.

Este trabajo es relevante y oportuno porque proporciona una guía metodológica práctica sobre el uso de DML específicamente en diseños de Diferencias en Diferencias (DiD) y una evidencia empírica para distintos contextos de DiD. DiD es una de las herramientas más populares en evaluación de políticas públicas, pero también una donde los supuestos tradicionales están siendo cuestionados en ciertos contextos (Goodman-Bacon, 2021). Mostrar cómo DML puede robustecer estos análisis tiene un valor directo para investigadores y profesionales en economía, ciencia de datos y políticas públicas.

3. Planteamiento del tema/problema

El problema central de investigación es comparar los resultados de estimadores tradicionales frente a DML en distintos contextos de DiD, identificando escenarios donde no hay discrepancias significativas y, crucialmente, escenarios donde sí las hay.

En la práctica econométrica actual, el diseño de Diferencias en Diferencias (DiD) es el estándar para estimar efectos causales con datos de panel observacionales. El estimador convencional para implementarlo ha sido la regresión de Efectos Fijos de Dos Vías (*Two-Way Fixed Effects* - TWFE).

Sin embargo, una literatura reciente y creciente (Goodman-Bacon, 2021; Callaway & Sant'Anna, 2021) ha demostrado que TWFE puede presentar sesgos significativos, especialmente en configuraciones de adopción escalonada, donde las unidades reciben el tratamiento en diferentes momentos. En estos casos, TWFE realiza comparaciones indebidas (por ejemplo, usar unidades tratadas temprano como control para unidades tratadas tarde), lo que puede resultar en estimaciones del efecto del tratamiento sesgadas.

Además del problema temporal, existe el problema de las covariables. TWFE asume típicamente que las covariables ingresan en el modelo de forma lineal y aditiva. Si la realidad es que las covariables interactúan entre sí de formas complejas o tienen efectos no lineales, TWFE estará mal especificado. En dichas circunstancias, DML promete una mejora sustancial: Al emplear algoritmos de aprendizaje automático para aproximar la forma funcional de los datos, DML permite controlar de manera más eficaz el efecto de las variables de control que una regresión lineal tradicional. Además, evita exigir que el investigador conozca de antemano la forma funcional exacta, un supuesto que en la práctica suele ser difícil de cumplir y que puede conducir a simplificaciones excesivas.

Para estudiar estos sesgos en profundidad, luego de establecer el marco teórico, se realizará un ejercicio de simulaciones que permita identificar en qué condiciones los estimadores tradicionales presentan sesgos significativos y, por lo tanto, justifican el costo de implementar DML.

El objetivo no es simplemente aplicar un algoritmo más complejo, sino evaluar si esa complejidad adicional se traduce en una mejor estimación cuando las circunstancias lo requieren. Una vez identificados esos casos mediante simulaciones, se aplicarán los estimadores a datos reales para validar los hallazgos.

Por lo tanto, se plantea la siguiente pregunta guía: ¿Cuándo el DML y TWFE presentan diferencias sustanciales en diseños de Diferencias en Diferencias? Específicamente: ¿En qué condiciones de diseño (tratamiento simultáneo vs. adopción escalonada, dimensionalidad de covariables) los estimadores DML y TWFE producen resultados equivalentes? ¿En qué escenarios DML captura efectos de tratamiento que TWFE no logra identificar correctamente, y qué explica esas divergencias? ¿Qué criterios prácticos

puede seguir un investigador aplicado para decidir entre DML y TWFE en un diseño de DiD?

En el desarrollo de este proyecto de investigación, también se mencionan las limitaciones de DML y de las técnicas de inferencia causal en general para presentar una visión balanceada de cada metodología y contexto.

4. Objetivos

Objetivos generales

Comparar los resultados de los estimadores de *Double Machine Learning* (DML) y TWFE aplicados a diseños de Diferencias en Diferencias (DiD), con el fin de proporcionar a los investigadores aplicados una guía metodológica sobre cuándo y cómo utilizar estas técnicas avanzadas frente a los métodos econométricos tradicionales.

Objetivos específicos

(1) Describir y formalizar el marco clásico de Diferencias en Diferencias y sus herramientas econométricas, así como sus limitaciones, (2) Explicar teóricamente el marco de *Double Machine Learning* (DML), incluyendo conceptos clave como la ortogonalidad de Neyman y el *cross-fitting*, (3) Evaluar mediante simulaciones el desempeño de los estimadores TWFE y DML, variando el momento de aplicación del tratamiento y la complejidad de los datos y (4) Implementar y comparar estimadores DML para diseños DiD en dos contextos: tratamiento simultáneo y adopción escalonada.

5. Hipótesis

La investigación se guía por las siguientes hipótesis de trabajo, diferenciadas por el tipo de diseño cuasi-experimental:

Hipótesis 1 (Escenarios Simples / Canónicos):

En diseños de Diferencias en Diferencias con tratamiento simultáneo (todas las unidades tratadas comienzan en la misma fecha) y un número moderado de covariables, los estimadores DML y TWFE presentarán resultados similares. En estos casos, el estimador

TWFE es insesgado bajo tendencias paralelas básicas, y la especificación lineal suele ser una aproximación suficiente. La complejidad adicional del DML no aportará una reducción significativa del sesgo.

Hipótesis 2 (Escenarios Complejos / Adopción Escalonada):

En diseños de Adopción Escalonada (*Staggered Adoption*), especialmente aquellos con heterogeneidad en el efecto del tratamiento, el estimador TWFE presentará sesgos significativos, mientras que el estimador DML recuperará el efecto causal del tratamiento promedio correcto sobre los tratados (*Average treatment on the treated*, ATT).

6. Marco teórico (preliminar)

El marco teórico de esta tesis integra dos literaturas que tradicionalmente han evolucionado por separado: la econometría de evaluación de impacto (específicamente Diferencias en Diferencias) y el aprendizaje automático supervisado, mediante una metodología relativamente nueva llamada *Double Machine Learning*.

Diferencias en Diferencias (DiD)

El método de Diferencias en Diferencias es una de las estrategias de identificación más populares en economía aplicada para estimar efectos causales cuando no es posible realizar un experimento aleatorizado (Cunningham, 2021).

En su forma más simple (2 periodos, 2 grupos), el estimador DiD compara el cambio temporal en el grupo de tratamiento con el cambio temporal en el grupo de control. Formalmente, si Y_{it} es el resultado para la unidad i en el tiempo t , el estimador se define como:

$$\widehat{\delta_{DiD}} = (\overline{Y_{post}^{Tratado}} - \overline{Y_{pre}^{Tratado}}) - (\overline{Y_{post}^{Control}} - \overline{Y_{pre}^{Control}})$$

Esta doble diferencia elimina dos tipos de sesgos potenciales:

1. Diferencias permanentes entre los dos grupos (efectos fijos de unidad).
2. Tendencias temporales comunes que afectan a ambos grupos por igual (efectos fijos de tiempo).

Bajo ciertas condiciones, este estimador recupera el Efecto Promedio del Tratamiento en los Tratados (ATT), definido como $E[Y^1 - Y^0|D = 1]$, donde Y^1 y Y^0 son los resultados potenciales con y sin tratamiento, respectivamente.

La validez del estimador DiD depende del supuesto de tendencias paralelas. Este supuesto establece que, en ausencia de tratamiento, la evolución promedio del resultado habría sido idéntica para ambos grupos. Matemáticamente:

$$E[Y_t^0 - Y_{t-1}^0|D = 1] = E[Y_t^0 - Y_{t-1}^0|D = 0]$$

Si este supuesto no se cumple, el cambio observado en el grupo de control no es un contrafactual válido para el grupo de tratamiento, y el estimador DiD estará sesgado.

A pesar de su popularidad, la implementación estándar del DiD mediante regresión de mínimos cuadrados ordinarios (TWFE) enfrenta desafíos importantes que han sido destacados por la literatura econométrica reciente. En muchas aplicaciones modernas, el tratamiento no se implementa al mismo tiempo para todas las unidades, sino que se adopta de forma escalonada. En Goodman-Bacon (2021) se demostró que el estimador TWFE estándar en estos contextos es una media ponderada de todas las posibles comparaciones de 2x2. Problemáticamente, algunas de estas ponderaciones pueden ser negativas, especialmente cuando los efectos del tratamiento varían en el tiempo. Esto puede llevar a situaciones paradójicas donde el estimador TWFE tiene el signo opuesto al verdadero efecto promedio. A menudo, el supuesto de tendencias paralelas sin incluir covariables es inverosímil. Por ejemplo, estados con diferentes características demográficas pueden tener tendencias de criminalidad naturales distintas. En estos casos, es necesario asumir tendencias paralelas condicionales: las tendencias son iguales dado un vector de covariables observable X .

La práctica estándar es incluir X linealmente en la regresión ($Y \sim D + X$). Sin embargo, esto asume que sabemos exactamente cómo X afecta a Y (forma funcional). Si la relación es no lineal o implica interacciones complejas, el modelo lineal está mal especificado, reintroduciendo sesgo.

Double Machine Learning (DML)

Double Machine Learning, (Chernozhukov et al., 2018), es un marco general para estimar parámetros causales estructurales en presencia de muchas variables de control con efectos complejos tanto en el tratamiento como en la variable dependiente. Estos efectos se

cuantifican mediante *nuisance functions* que deben ser estimadas con modelos flexibles con el fin de evitar que los controles generen un sesgo es la estimación del efecto del tratamiento. El punto de partida es a menudo un modelo parcialmente lineal (PLM):

$$Y = D\theta_0 + g_0(X) + \epsilon$$

$$D = m_0(X) + \eta$$

Donde Y es el resultado, D es el tratamiento, y θ_0 es el parámetro causal de interés. Crucialmente, $g_0(X)$ (la relación entre covariables y resultado) y $m_0(X)$ (la relación entre covariables y tratamiento, o *propensity score*) son funciones desconocidas y potencialmente muy complejas.

Si intentáramos estimar θ_0 y $g_0(X)$ simultáneamente usando ML (e.g., *Random Forest*), el sesgo de regularización inherente al ML (necesario para evitar *overfitting*) se "contagiaría" a la estimación de θ_0 , resultando en un estimador sesgado y una inferencia inválida.

DML resuelve esto mediante un proceso de dos etapas basado en el teorema de Frisch-Waugh-Lovell "generalizado". La idea es "ortogonalizar" el problema:

1. Predecir Y usando X y obtener los residuos: $\tilde{Y} = Y - \hat{E}[Y|X]$.
2. Predecir D usando X y obtener los residuos: $\tilde{D} = D - \hat{E}[D|X]$.
3. Regresar $\tilde{Y}$ sobre $\tilde{D}$ para estimar θ_0

Esta estructura satisface la condición de Ortogonalidad de Neyman, lo que significa que el estimador de θ_0 es localmente insensible a pequeños errores en la estimación de las funciones molestas g_0 y m_0 . Esto permite usar algoritmos de ML ("cajas negras") para estimar g_0 y m_0 y aún así obtener inferencia válida de $\sqrt{N}$ -consistente para θ_0 .

Para evitar otro sesgo conocido como "*overfitting bias*" (usar los mismos datos para seleccionar el modelo y estimar el efecto), DML emplea *Cross-Fitting*:

1. Dividir la muestra en K *folds*.
2. Para cada *fold* k , usar el resto de los datos (complemento) para entrenar los modelos de ML.
3. Usar los modelos entrenados para generar residuos en el *fold* k .
4. Promediar los resultados.

Esto rompe la correlación espuria entre las estimaciones de las funciones molestas y los términos de error.

DML aplicado a Diferencias en Diferencias

Recientemente, autores como Chang (2020) han extendido los principios de DML a configuraciones de panel y DiD. Los estimadores resultantes son doblemente robustos: es consistente si $g(X)$ o $m(X)$ están correctamente especificados, y es eficientemente óptimo cuando ambos lo están. Esto contrasta con TWFE, que requiere que la especificación lineal sea correcta.

7. Metodología y técnicas a utilizar

La presente investigación adopta un enfoque cuantitativo bajo un diseño de simulación y observacional cuasi-experimental. La base de la estrategia empírica consiste en un análisis comparativo que aplica tanto estimadores tradicionales de *Two-Way Fixed Effects* (TWFE) como *Double Machine Learning* (DML). El objetivo de este contraste es evaluar las diferencias en la estimación de efectos causales cuando se utilizan estructuras de datos de distinta complejidad.

Ejercicio de Simulación

Se realizará un ejercicio de simulación donde se generarán distintos escenarios de datos de panel, variando condiciones clave como la estructura temporal del tratamiento (simultáneo vs. escalonado), la heterogeneidad de los efectos y la complejidad de la relación entre covariables y la variable de respuesta. Esto permite observar, en un entorno controlado, bajo qué configuraciones el estimador TWFE presenta sesgos y en cuáles el DML logra corregirlos, estableciendo así un punto de referencia para interpretar los resultados de los casos empíricos que siguen.

Casos de Estudio y Fuentes de Datos

Para evaluar la robustez de ambas metodologías, se han seleccionado dos casos empíricos con estructuras de distinta complejidad. El primer escenario analiza el impacto de la expansión del *fracking* sobre la actividad regulatoria ambiental en Estados Unidos mediante un diseño canónico. Con un tratamiento simultáneo iniciado en 2005, se utiliza un panel balanceado a nivel de código postal-año con más de 143,000 observaciones. En este

contexto, donde la relación entre la exposición a los pozos (D) y los resultados regulatorios (Y) se modela con un set acotado de covariables económicas (X), la hipótesis plantea que el estimador TWFE y el DML arrojarán resultados similares.

Por el contrario, el segundo caso aborda la evaluación de las leyes de defensa propia (*Castle Doctrine*) sobre las tasas de homicidio estatales en un diseño de adopción escalonad. En este esquema, la entrada en vigor de la ley varía entre los 50 estados durante el periodo 2000-2010. Dada la evolución heterogénea de variables demográficas y socioeconómicas complejas, se anticipa que el estimador tradicional TWFE presente sesgos significativos. Se espera que el DML, al capturar mejor estas interacciones, revele efectos causales más precisos y alineados con la literatura que critica la utilización de modelos de efectos fijos tradicionales para este tipo de datos.

Implementación Técnica y Algoritmos

La implementación del DML se centra en la estimación precisa de las *nuisance functions*: la función de regresión de los resultados $g(X)=E[Y|X,D=0]$ y el modelo de propensión o exposición $m(X)=E[D|X]$. Para abordar las no linealidades e interacciones automáticas sin recurrir a un preprocesamiento exhaustivo, se emplean algoritmos basados en árboles de decisión. En el caso del *fracking*, se opta por *LightGBM* debido a su eficiencia computacional en muestras grandes. Para el caso de las leyes de defensa propia, se utiliza *Random Forest*, aprovechando su robustez en conjuntos de datos estatales más densos pero de menor escala.

Todo el flujo de trabajo se desarrolla en Python, integrando el ecosistema de *scikit-learn*, *statsmodels* y *doubleml* con una implementación personalizada del estimador de Chang (2020).

8. Cronograma

Se presentará un cuadro de doble entrada en el que se especificarán en las filas las actividades a realizar y en las columnas los períodos de tiempo (diagrama de Gantt).

Actividad	Meses del año 2026											
	1	2	3	4	5	6	7	8	9	10	11	12
Actividad 1: Sumar la simulación	X	X										

Actividad	Meses del año 2026											
	1	2	3	4	5	6	7	8	9	10	11	12
Actividad 2: Revisión extra de bibliografía			X	X				X				
Actividad 3: Revisión y edición					X							
Actividad 4: presentar en un seminario y/o conferencia						X	X					
Actividad 5: incorporar comentarios de seminario								X	X			

9. Referencias bibliográficas y bibliografía (preliminar)

Breiman, L. (2001a). Random forests. *Machine Learning*, 45(1), 5–32.

Breiman, L. (2001b). Statistical modeling: The two cultures (with comments and a rejoinder by the author). *Statistical Science*, 16(3), 199–231.

Callaway, B., & Sant’Anna, P. H. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.

Chang, N.-C. (2020). Double/debiased machine learning for difference-in-differences models. *The Econometrics Journal*, 23(2), 177–191.

Cheng, C., & Hoekstra, M. (2013). Does strengthening self-defense law deter crime or escalate violence? Evidence from expansions to castle doctrine. *The Journal of Human Resources*, 48(3), 821–853.

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Cunningham, S. (2021). (Cunningham, 2021). Yale University Press.

Desai, A. (2023). *Machine learning for economics research: When, what and how?* [Working Paper]. SSRN.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The*

- Annals of Statistics*, 29(5), 1189–1232.
- González, J. P. (2025). Environmental regulation, regulatory spillovers and rent-seeking. *Public Choice*, 202(1), 217–250.
- Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS'17)* (pp. 3149–3157). Curran Associates Inc.
- Molnar, C. (2025). *Interpretable machine learning* (3rd ed.).
- Mullainathan, S., & Spiess, J. (2017). Machine learning: An applied econometric approach. *Journal of Economic Perspectives*, 31(2), 87–106.
- Pritchett, L. (2024). “Rely (only) on the rigorous evidence” is bad advice. *Review of Development Economics*, 28(4), 2034–2058.
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3), 289–310.
- Varian, H. R. (2014). Big data: New tricks for econometrics. *Journal of Economic Perspectives*, 28(2), 3–28.
- Wüthrich, K., & Zhu, Y. (2023). Omitted variable bias of lasso-based inference methods: A finite sample analysis. *The Review of Economics and Statistics*, 105(4), 982–997.

.UBAeconómicas **posgrado**

ENAP Escuela de Negocios y Administración Pública